Comparación de tres métodos de segmentación de imágenes RGB para identificar cobertura vegetal en *Arabidopsis thaliana*



José Manuel Ramírez Londoño / **María Valentina Smith Silva**

Universidad EAFIT — Ingeniería Agronómica

Asignatura: Big Data y Bioinformática

Profesora: Luisa Fernanda Gómez Ossa

Octubre de 2026

Contenido

1 | Introducción y problema de investigación

2 | Dataset y accesiones

3 | Metodología
Segmentación, entrenamiento y limpieza

4 | Evaluación
Métricas y área proyectada

5 | Resultados
Comparación entre métodos y accesiones

6 | Discusión, conclusiones y aplicación agronómica

¿Por qué estudiar *Arabidopsis thaliana*?



Figura 1. Desarrollo de *Arabidopsis thaliana* en condiciones de cultivo y máscara de segmentación.

Planta modelo

Especie ampliamente utilizada en investigación para estudiar genética, fisiología y desarrollo vegetal.

Crecimiento observable

Sus hojas se organizan en una roseta, cuya superficie visible puede registrarse mediante fotografías tomadas desde arriba.

Fenotipado digital

La segmentación permite separar las hojas del suelo y la maceta para cuantificar su cobertura proyectada.

Aplicación agronómica

Estos métodos sirven como base para analizar crecimiento, respuestas al estrés y diferencias entre genotipos, siempre que se validen para cada aplicación.

La segmentación convierte **fotografías en mediciones de la cobertura vegetal,** útiles para el seguimiento del crecimiento y el análisis fenotípico de las plantas.

Problema de investigación

La presencia de suelo, sombras y bordes de la maceta dificulta la identificación automática de la superficie vegetal en fotografías RGB.

¿Cuál de los tres métodos permite identificar con mayor precisión los píxeles de planta?



Figura 2a. Fotografía RGB de una planta.



Figura 2b. Máscara binaria correspondiente.

Dataset utilizado

Plant Growth Segmentation Dataset · Kaggle

2.008
Fotografías RGB

2.008
Máscaras de referencia

38
Accesiones disponibles

Selección para el análisis

161 imágenes RGB
de 3 accesiones

C24	Ba4-1	Can-0
55 imágenes (38 desarrollo / 17 prueba)	**55 imágenes**	**51 imágenes**



Máscara de referencia: píxeles de planta RGB (250, 50, 83); fondo en negro (0, 0, 0).

Cada fotografía tiene una máscara asociada, utilizada como referencia para el entrenamiento y la evaluación de la segmentación.

Metodología

Preparación y segmentación

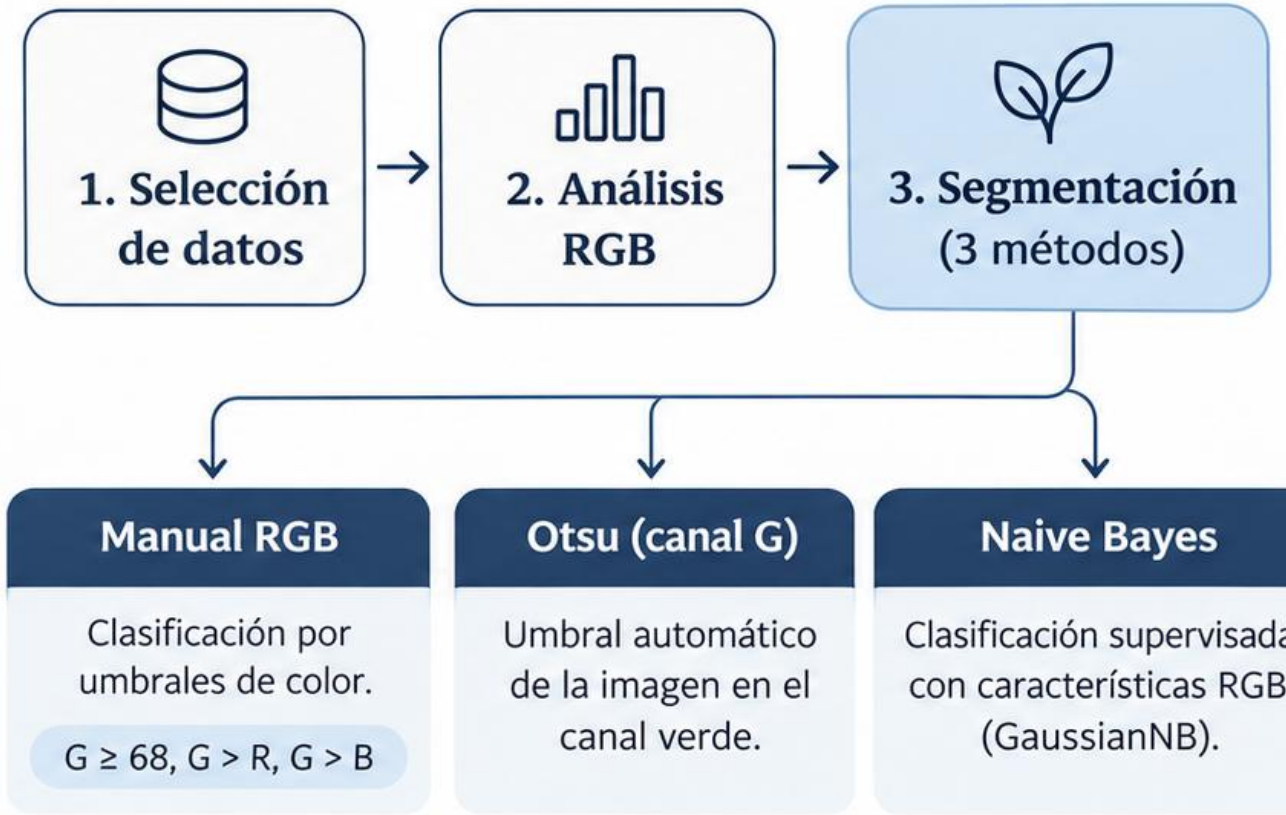
Se implementó un flujo de trabajo para segmentar la superficie vegetal en imágenes RGB, comparando tres métodos de segmentación.

Datos y organización

Plant Growth Segmentation Dataset
1.898 imágenes y máscaras • 38 accesiones

C24	**55** imágenes	**38** desarrollo **17** prueba interna
Ba4-1	**55** imágenes	Evaluación adicional
Can-0	**51** imágenes	Evaluación adicional

Flujo de trabajo



Métodos de segmentación

Enfoques para la delimitación de la superficie vegetal

Manual RGB

Clasificación por reglas de color en el espacio RGB.

$G \geq 68,\ G > R,\ G > B$

- Umbral definido a partir del análisis de los histogramas.
- No requiere entrenamiento.

Otsu (G)

Umbral automático por imagen.

`threshold_otsu(G)`

- Se aplica sobre el canal verde (G).
- Se mantiene el criterio de predominio G > R y G > B.
- No requiere entrenamiento.

Naive Bayes

Clasificación supervisada con GaussianNB.

`GaussianNB().fit(X_train, y_train)`

- Variables: R, G y B normalizadas (0–1).
- Entrenado con muestras de píxeles de planta y fondo de las imágenes de desarrollo.

Análisis de color

Se analizaron los histogramas de los canales RGB para identificar la separación entre planta y fondo y definir los umbrales.

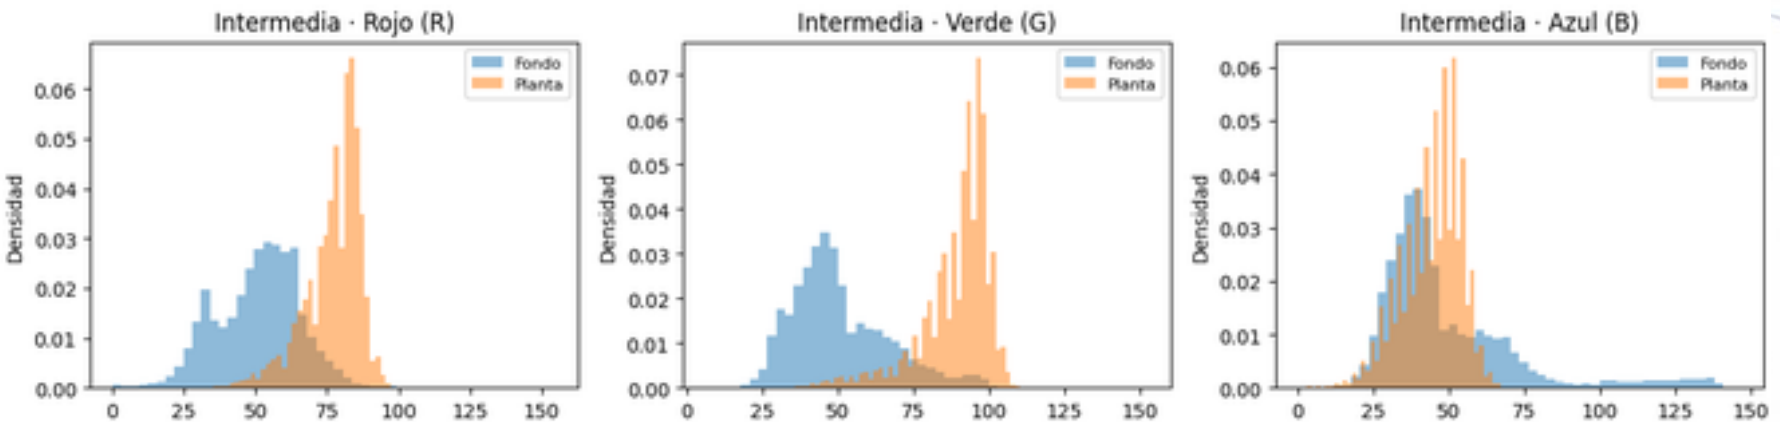


Figura 3. Histogramas de los canales RGB que justifican los umbrales de segmentación.

Metodología

Posprocesamiento y evaluación

Las máscaras generadas por cada método se refinaron con operaciones morfológicas y se evaluó su desempeño frente a la máscara de referencia.

Flujo de trabajo (etapas 3–4)

3. Posprocesamiento
(limpieza morfológica)

→

4. Evaluación
(métricas de desempeño)

Operaciones morfológicas

Cierre
Conecta regiones y reduce huecos.

Apertura
Elimina ruido (objetos pequeños).

Eliminación de ruido
Descarta componentes de área menor a un umbral.

Relleno de huecos
Completa la región de la planta.

Evaluación del desempeño

Precisión	$TP / (TP + FP)$
Recall	$TP / (TP + FN)$
IoU	$TP / (TP + FP + FN)$
Error de área	$\lvert A_{est} - A_{ref} \rvert / A_{ref} \times 100$

Librerías principales (Python)

scikit-image (morfología)

scikit-learn (GaussianNB)

NumPy (operaciones)

Matplotlib (visualización)

Limpieza morfológica

Efecto del posprocesamiento en la segmentación

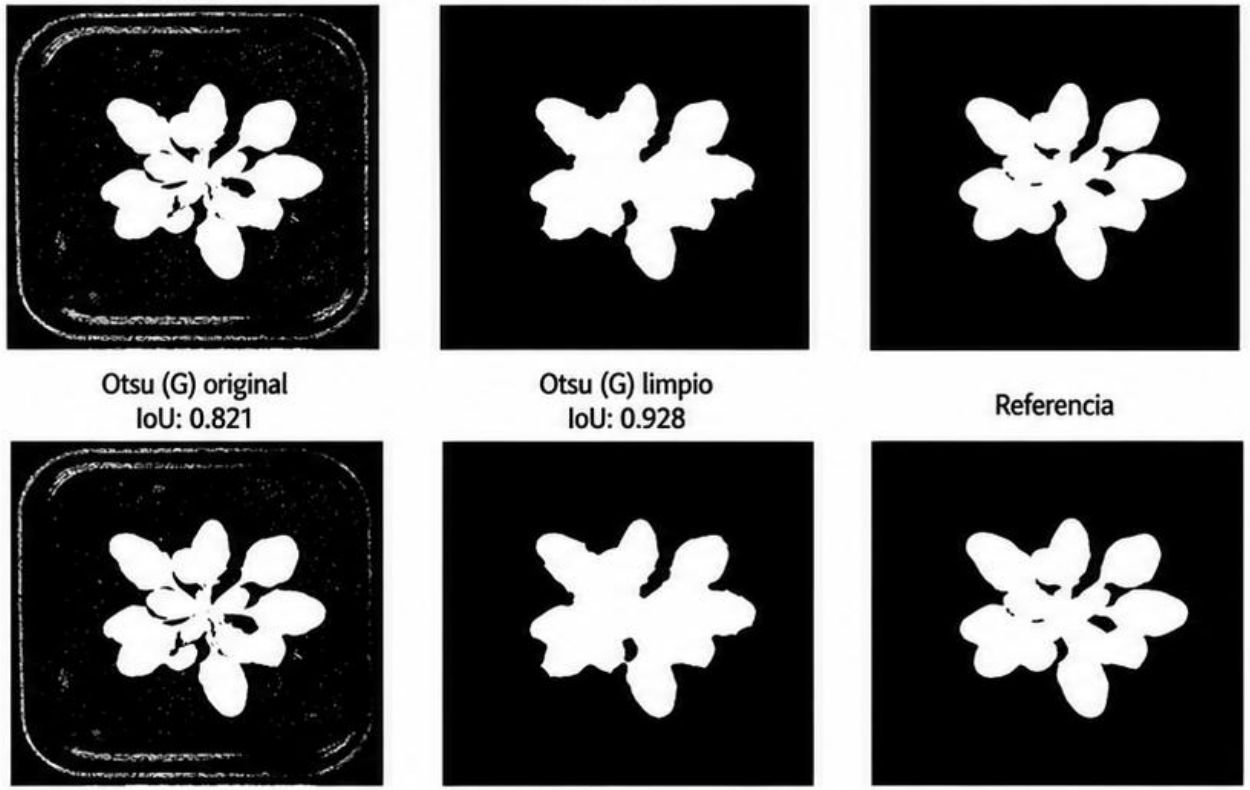


Figura 4. Efecto de la limpieza morfológica en las segmentaciones Manual RGB y Otsu (G).

Desempeño de la segmentación

Método	IoU original	IoU limpio
Manual RGB	0.803	0.932
Otsu (G)	0.821	0.928

Resultados clave

- La limpieza morfológica eliminó el ruido del fondo y mejoró la continuidad de la máscara.
- Se aumentó el IoU en **0.129** para Manual RGB (0.803 → 0.932) y en **0.107** para Otsu (0.821 → 0.928).

Comparación visual de los métodos

Segmentaciones finales y comparación con la referencia

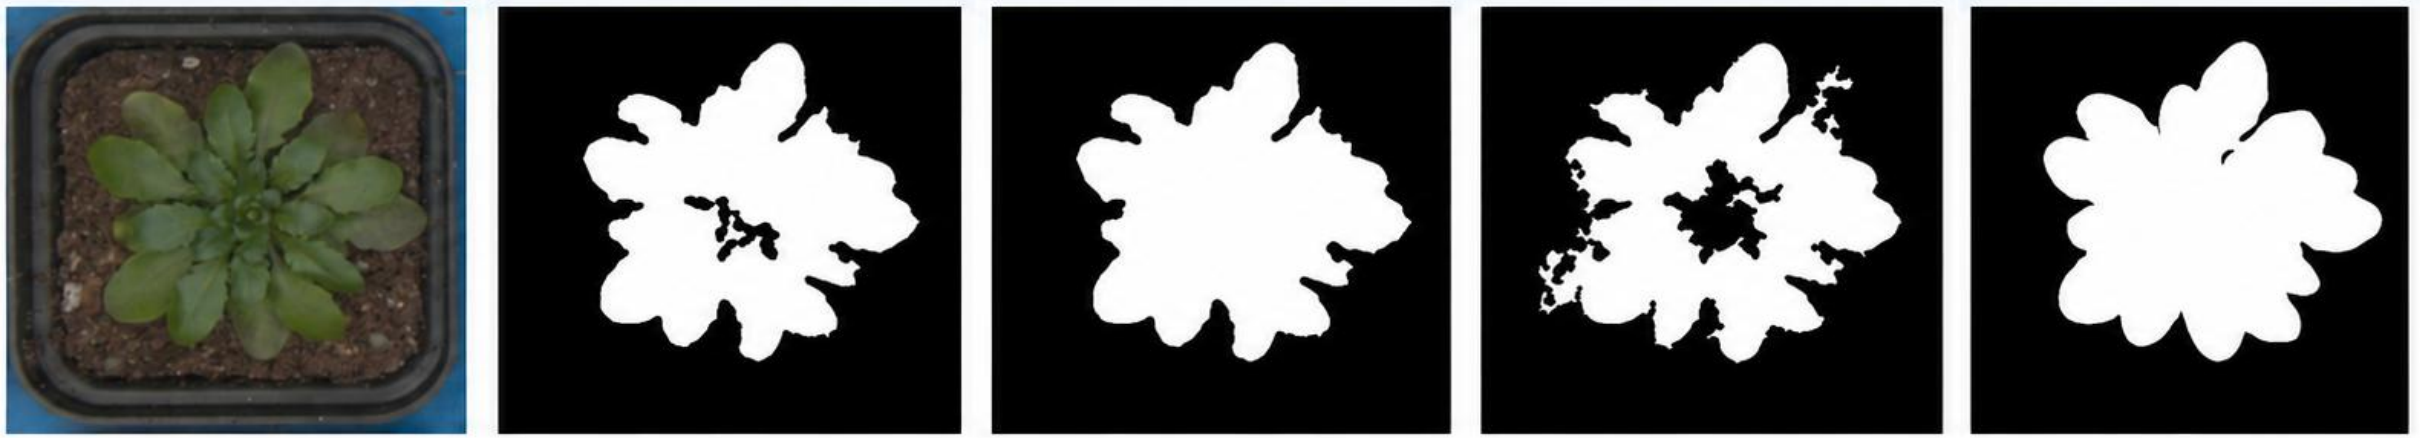


Figura 5. Comparación de las segmentaciones obtenidas por Manual RGB, Otsu (G) y Naive Bayes con la máscara de referencia.

Observaciones

Manual RGB Buena delimitación general, con pérdidas en algunos sectores de las hojas.

Otsu (G) Máscara más continua y cercana a la referencia.

Naive Bayes Mayor variación de la delimitación, con regiones faltantes y ruido, especialmente en zonas oscuras.

Desempeño por accesión

Métricas de evaluación por accesión y método

Accesión	Método	Precisión	Recall	IoU
Ba4-1	Manual RGB	0.982	0.806	0.790
	Naive Bayes	0.986	0.853	0.841
	Otsu (G)	0.950	0.874	0.846
C24	Manual RGB	0.991	0.908	0.900
	Naive Bayes	0.971	0.856	0.835
	Otsu (G)	0.968	0.953	0.923
Can-0	Manual RGB	0.977	0.927	0.908
	Naive Bayes	0.953	0.937	0.895
	Otsu (G)	0.971	0.940	0.915

Tabla 1. Precisión, recall e IoU por accesión y método.

Resultados clave

Otsu (G) obtuvo el mayor IoU en todas las accesiones:
Ba4-1 (0.846), C24 (0.923) y Can-0 (0.915).

Manual RGB alcanzó la mayor precisión en las tres accesiones:
Ba4-1 (0.982), C24 (0.991) y Can-0 (0.977).

Naive Bayes presentó el menor desempeño global, con los IoU màs bajos:
Ba4-1 (0.841), C24 (0.835) y Can-0 (0.895).

En las tres accesiones, **Otsu (G)** mostró la mejor coincidencia con la referencia, mientras que **Manual RGB** alcanzó la **mayor precisión**.

Error absoluto medio del área proyectada

Comparación por método y accesión

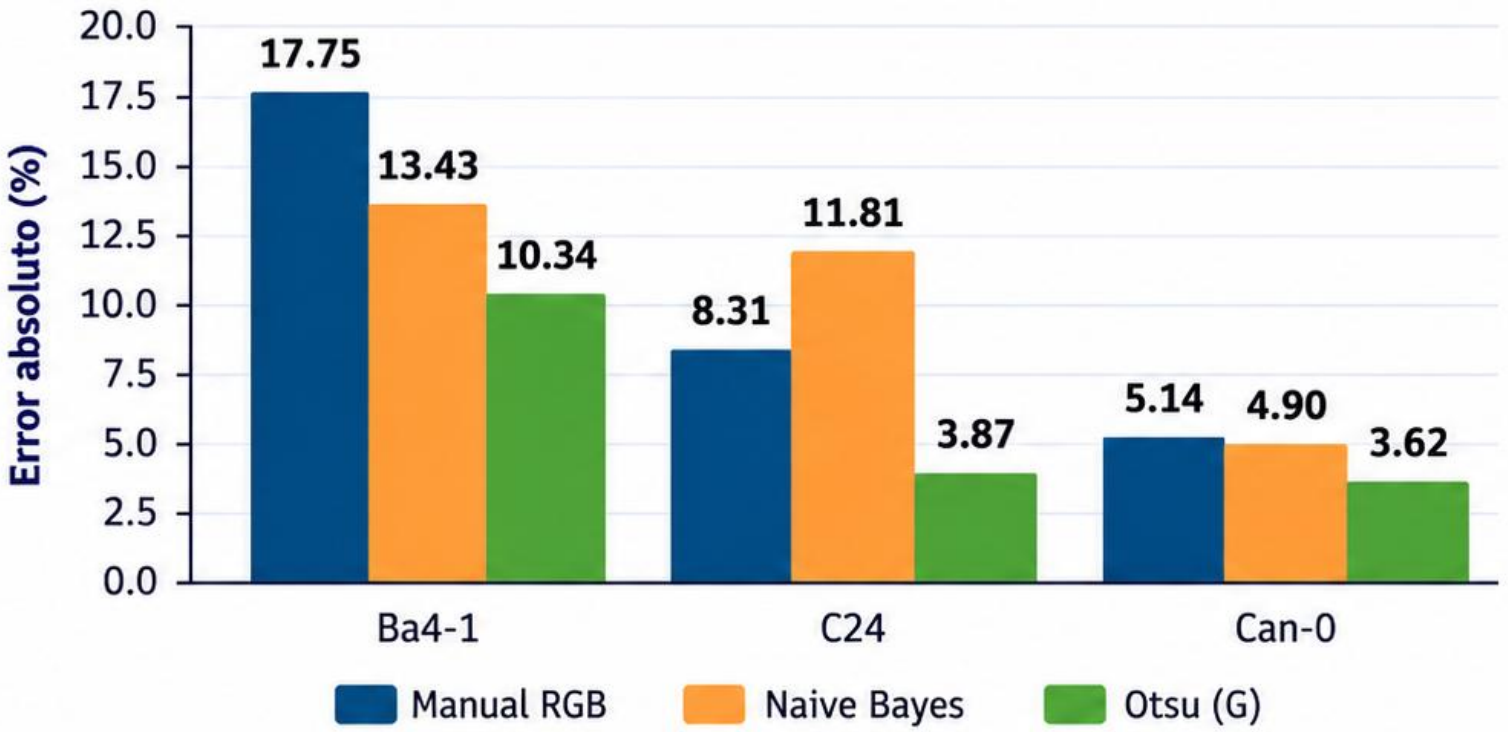


Figura 6. Error absoluto porcentual medio del área proyectada por método y accesión.

Hallazgos clave

Otsu (G) presentó el menor error absoluto en las tres accesiones: 10.34 % (Ba4-1), 3.87 % (C24) y 3.62 % (Can-0).

Naive Bayes fue intermedio, con un mayor error en C24 (11.81 %).

Manual RGB mostró el mayor error en Ba4-1 (17.75 %).

En conjunto, Otsu (G) fue el método más preciso, con el menor error absoluto en las tres accesiones.

Segmentación de Otsu durante el desarrollo vegetal

Evolución de la segmentación en la accesión C24



Figura 7. Comparación de fotografías RGB, segmentación con Otsu y limpieza morfológica, y máscaras de referencia en nueve imágenes de la accesión C24.

Observaciones

- Otsu identificó adecuadamente la cobertura vegetal proyectada a lo largo del desarrollo.
- Las diferencias con la referencia fueron principalmente pequeñas variaciones en los contornos y, en la imagen 55, la inclusión de píxeles de la maceta.

Conclusiones y aplicación agronómica

Resultado: Otsu alcanzó el mayor IoU medio y el menor error absoluto porcentual medio de área en las tres accesiones.

Aplicación: la segmentación RGB permite estimar la cobertura vegetal proyectada mediante el conteo de píxeles.

Limitaciones: la precisión depende de las condiciones de imagen; las máscaras de referencia no equivalen a mediciones físicas de área foliar y los resultados no pueden generalizarse sin nuevas pruebas.

La selección del método de segmentación influye directamente en la precisión de las mediciones vegetales obtenidas a partir de imágenes digitales.

Referencias

- Kaggle. Plant Growth Segmentation Dataset.
- Otsu, N. (1979). A threshold selection method from gray-level histograms.
- Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python.
- van der Walt, S. et al. (2014). scikit-image: Image processing in Python.